TECHNICKÁ UNIVERZITA V LIBERCI
Fakulta mechatroniky, informatiky
a mezioborových studií

Vyhledávání

a deep learning

František Kynych
27. 10. 2022 | MVD

Opakování z minulé přednášky

TF-IDF

- Výsledná rovnice při použití TF-IDF a počítání relevance pomocí skalárního součinu:

$$sim(q,d) = \sum_{i=1}^{N} x_i y_i = \sum_{w \in q \cap d} c(w,q)c(w,d)\log\left(\frac{M+1}{df(w)}\right)$$

M = celkový počet dokumentů v kolekci

df(w) = celkový počet dokumentů obsahující slovo w (document frequency)

Okapi BM25

- Výsledná rovnice BM25 při počítání relevance pomocí skalárního součinu:

$$sim(q,d) = \sum_{i=1}^{N} x_i y_i = \sum_{w \in q \cap d} c(w,q) \frac{(k+1)c(w,d)}{c(w,d) + k(1 - b + b\frac{|d|}{avdl})} log(\frac{M+1}{df(w)})$$

- V praxi se používá rozšířený BM25
  - BM25F pro strukturované dokumenty (F = fields)
  - BM25+ zabraňuje příliš velké penalizaci dlouhých dokumentů

- BM25 používá defaultně Elasticsearch

Limitace předchozích metod

- Bag-of-words
  - Rozdělení textu na jednotlivá slova
    - Nezáleží na pořadí slov v dotazu
- Fungují hůře při vyhledávání nad delšími dokumenty
- Problém při špatném definování dotazu
  - Nelze nalézt synonyma

- Pokud není potřeba řešit některý ze zmíněných problémů, tak je BM25(F/+) dostačující
  - Jinak se používá jako baseline

TECHNICKÁ UNIVERZITA V LIBERCI
Fakulta mechatroniky, informatiky
a mezioborových studií

Část I.:
Vylepšení vyhledávání a aplikace neuronových sítí

Kosinová podobnost

- Nezávislá na velikosti dokumentů

$$cossim(A,B) = \cos \emptyset = \frac{A \cdot B}{\|A\|\|B\|}$$

$$\|A\| = \sqrt{\sum_{i=1}^{N} A_i^2}$$

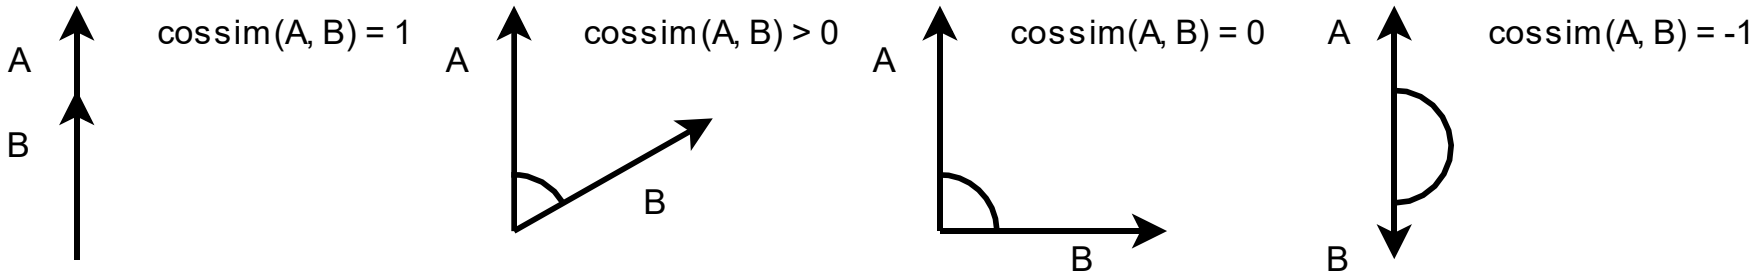

Základní vylepšení vyhledávání

1. Použití Word2Vec modelu místo TF-IDF/BM25
2. Generování synonym
3. Generování alternativních dotazů
4. Našeptávání uživateli

Word2Vec retrieval model

- Porovnání vektoru dotazu a dokumentu
- Jak tyto vektory vytvořit?
  - Průměr vektorů slov
    - Stejný problém jako na počátku – jedno četné slovo může ovlivnit výsledek
    - Funguje dobře při velkém množství trénovacích dat

  - Word2Vec v kombinaci s TF-IDF vyhlazováním
    - Funguje lépe při menším množství dat
    - Průměrujeme vážené Word2Vec vektory
    - Váhou každého slova je získané TF-IDF, např.:

$$query_{vec} = \frac{1}{|q|} \sum_{w \in q} word2vec(w) * tfidf(w)$$

Generování synonym

- Vytvoření dalších dotazů obsahující synonyma
  - Např. aeroplane -> plane, airplane, aircraft
  - Větší šance navrácení správného výsledku
- Rozšíření tokenizéru pro dotazy

- Základní přístupy:
  - Vytvoření souboru obsahující synonyma
    - Složité na tvorbu a údržbu
  - Použití již vytvořeného slovníku synonym pro daný jazyk
    - Např. WordNet pro angličtinu
    - Neexistuje pro každý jazyk

- Problém těchto přístupů:
  - Chybí kontext
  - Slang
  - Zkratky

Generování synonym

- Chceme nalézt nejbližšího souseda ke slovu analýzou jeho kontextu
  - Nemusí se jednat o synonymum z gramatického hlediska
  - Založeno na distribuční hypotéze

- Použití vektorové reprezentace slov – Word2Vec
  - Preferován skip-gram přístup
    - Lepší pro málo četná slova
  - Hledáme slova s největší kosinovou podobností

Generování synonym – Word2Vec

- U generování synonym je potřeba rozmyslet přístup k dané aplikaci
- Možnosti:
  - Generování synonym při indexování každého dokumentu
    - Při dlouhých dokumentech zabere velké množství místa
  - Generování synonym jen pro některé slovní druhy
    - Potřeba implementace part of speech (PoS) taggingu (podstatná slova, slovesa)
  - Zaměření na krátké dokumenty
    - Mají menší pravděpodobnost shody s dotazem
  - Zaměření pouze na častá slova
  - Generování synonym s vyšším prahem (pouze nejbližší slova)

Generování synonym – Word2Vec

- V produkci je potřeba pravidelně aktualizovat
- Pozor na antonyma (slova opačného významu)
  - Při menším množství trénovacích dat mohou mít antonyma velkou podobnost
  - Je potřeba otestovat pro cílovou aplikaci

Generování alternativních dotazů

- Označováno jako *automatic query expansion*
- Cílem je vygenerovat alternativní dotaz, který je sémanticky stejný
  - Chceme minimalizovat výskyt dotazů bez výsledků

- Např.: books about artificial intelligence -> publications from the field of artificial intelligence

- Kde získat data?
  - Procházení logů vyhledávání od uživatelů
    - Dotazy, které vrací podobné výsledky
    - Podobné dotazy od uživatele v daném časovém intervalu
    - Přidání textu z nalezených relevantních dokumentů

Generování alternativních dotazů

- Využití rekurentních neuronových sítí
  - Vysvětleno využitím Seq2Seq architektury
- Seq2Seq architektura se skládá z dvou částí
  - **Kodér**
    - Zpracuje vstupní informaci a poté předá skrytý stav do dekodéru
  - **Dekodér**
    - Přijme skrytý stav a generuje výstup

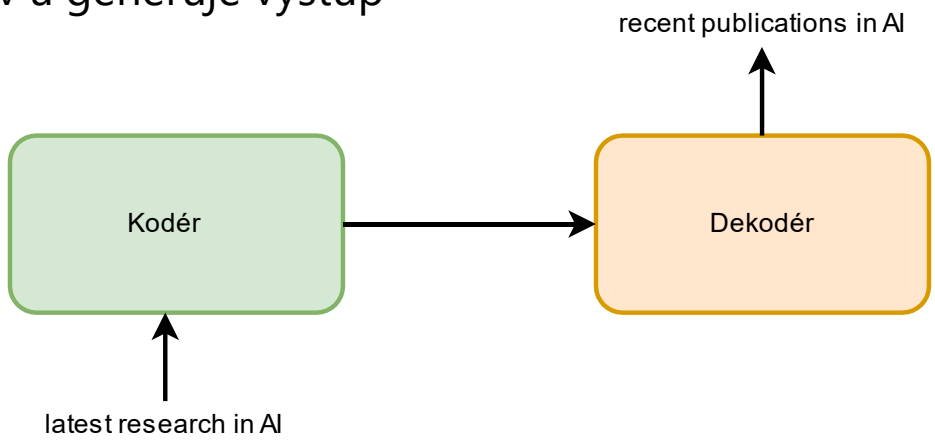

Generování alternativních dotazů

- Vstupní sekvence se ukončuje end-of-sequence tokenem (<EOS>)
  - Poté se začne generovat výstup
- Skrytý stav se zde také označuje jako myšlenkový vektor uživatele
- Dnes je lepší používat Transformer nebo novější architektury

Našeptávání uživateli

- Chceme, aby uživatel psal lepší dotazy
  - Autocomplete
  - Méně dotazů s žádnými výsledky nebo s malou relevancí výsledků

- Kde získat data?
  - Slovníky důležitých slov (např. nejčastěji hledané)
  - Dříve použité dotazy
  - Použití indexovaných dokumentů (např. titulky)

Našeptávání uživateli

- Použití slovníků
  - Prohledávání prefixového stromu
- Vyzkoušení vyhledávání na Googlu: „books about search“
  - Autocomplete postupně provádí:
    - Dokončení samostatných slov
    - Doporučení více slov najednou (nebo frází)
    - Odstraňuje některá napsaná slova (stopword filtr)
    - Nahrazuje některá slova
    - Při delším dotazu vynechává prefixová slova
- Často defaultně implementováno pomocí konečných automatů
  - Např. v třídě AnalyzingSugester v Apache Lucene

Našeptávání uživateli

- N-gram jazykové modely
  - Vychází z Markovovy vlastnosti
    - Pravděpodobnost budoucího slova záleží na přechozích slovech
- Použití bigramu (n=2)
  - Pravděpodobnost dalšího slova záleží na současném slovu

$$P(books\ about\ search) = P(about|books) \times P(search|about)$$

- Použito v třídě FreeTextSugester v Apache Lucene

Našeptávání uživateli

- Využití rekurentních neuronových sítí
  - Chceme, aby síť doplňovala uživatelský dotaz

- Rozšíření Word2Vec modelem
  - Natrénován na stejných datech jako našeptávání
  - Vytvoří alternativní dotaz na základě nejmenší vzdálenosti

Standardní přístup k vyhledávání

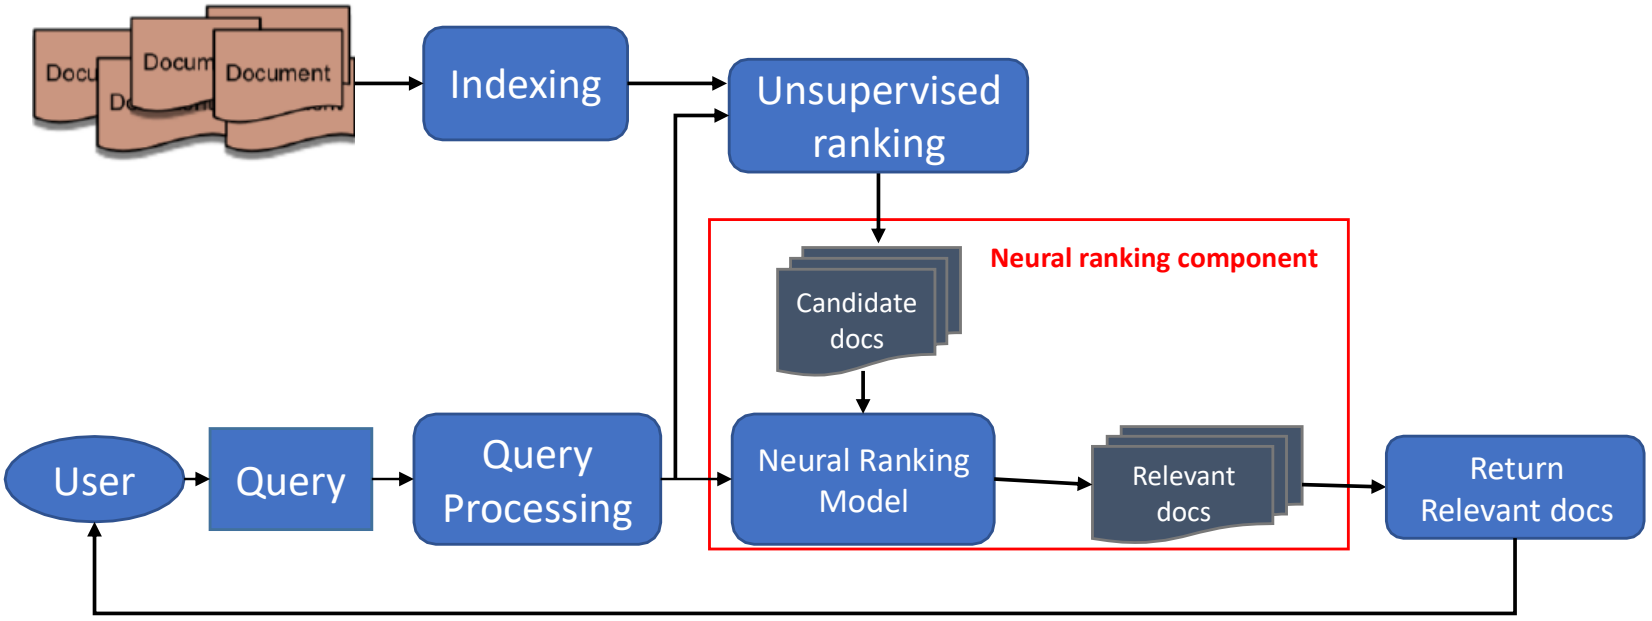

https://arxiv.org/pdf/2102.11903.pdf

Způsoby učení neuronové sítě

- Pointwise
  - Dataset dotazů a dokumentů s cílovým hodnocením pro každý dokument
  - Neuronová síť se učí správně ohodnotit dokumenty
  - Složitější vytvoření datasetu
- Pairwise
  - Funguje na principu binární klasifikace
  - Učí se určit, který ze dvou dokumentů je relevantnější
  - Více citlivá metoda na šum
  - Při špatném ohodnocení jednoho dokumentu může selhat i hodnocení všech dalších
- Ad-hoc (Listwise)
  - Dataset dotazů s listem cílových dokumentů
  - Neuronová síť se učí optimalizovat některou z metrik pro vyhledávání (např. NDCG) nebo se snaží modelovat pravděpodobnostní rozložení permutace

Representation-focused modely

- Modely extrahují informaci z dokumentu a z dotazu
  - Poté se použije kosinova podobnost pro hodnocení relevance
- Většinou tzv. siamská architektura

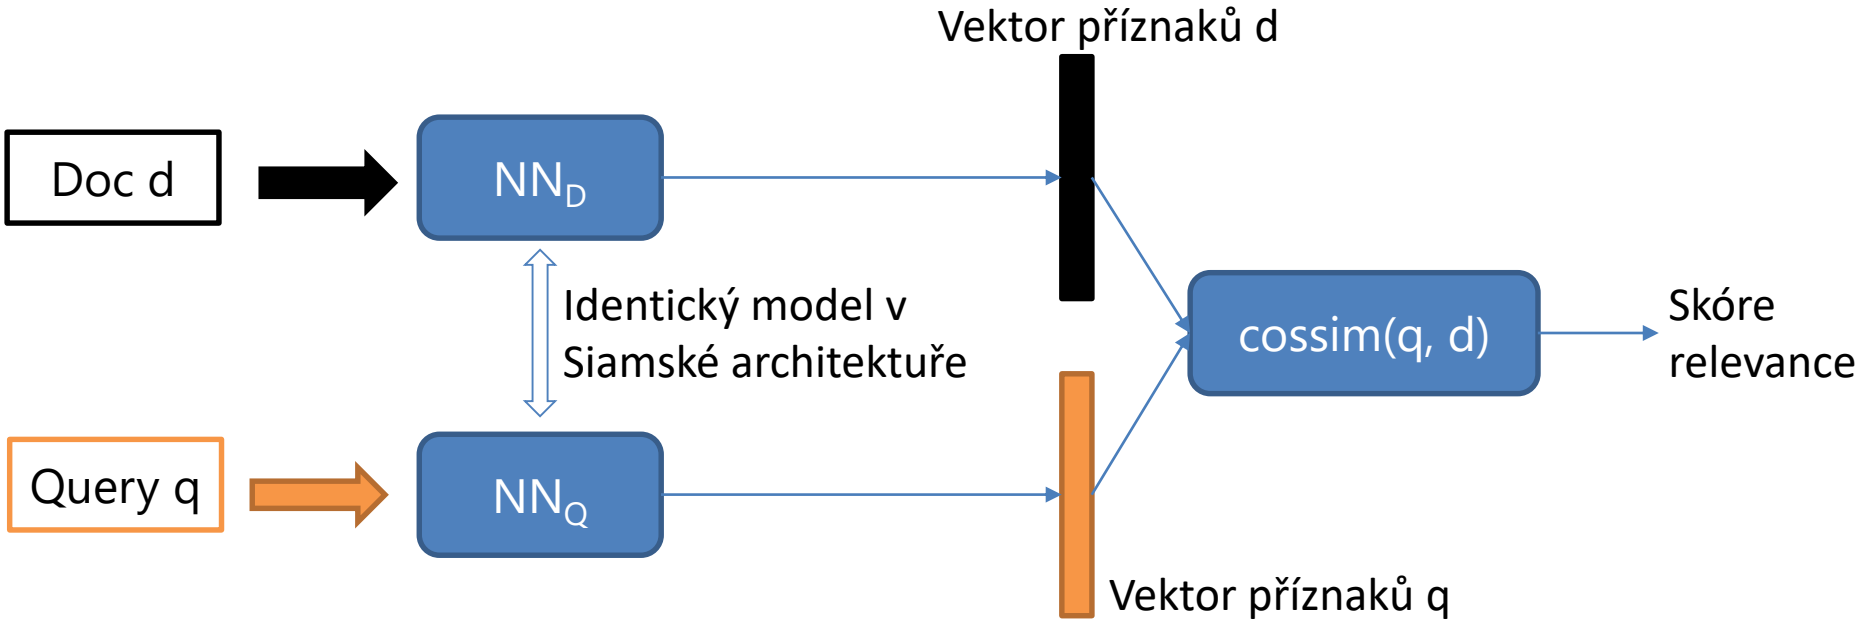

- Použití např. Convolution deep structured semantic modelu

Interaction-focused modely

- Modely, do kterých vstupuje najednou dotaz i dokument
- Interakční funkce
  - Model, který se snaží zachycovat vztah mezi dokumentem a dotazem (např. společná slova)
- Výstupní model počítá relevanci na základě příznaků z interakční funkce
- Např. Deep Relevance Matching Model

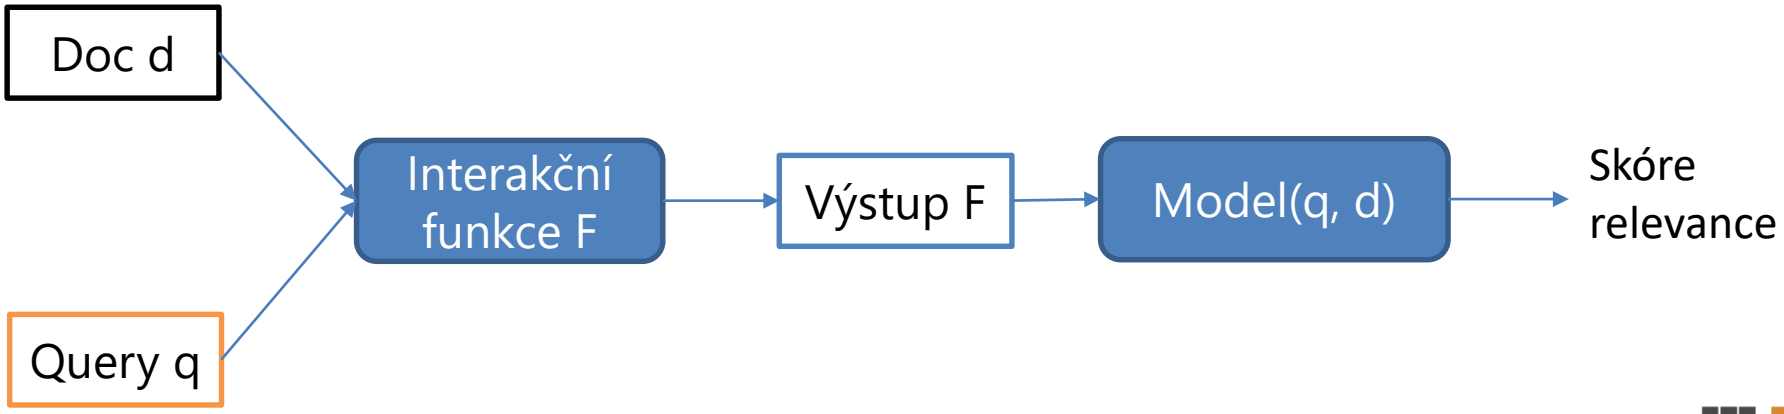

Využití předtrénovaných jazykových modelů

- Využití ELMO / BERT předtrénovaného modelu
  - Fine-tuning pro konečnou aplikaci

- BERT
  - Maximálně 512 vstupních tokenů
    - Dokument lze rozdělit na komponenty (věty)
    - Relevance dokumentu odpovídá top-k nejrelevantnějším komponentám
      => Výpočet relevance přes páry (dotaz, komponenta)
      => Relevance je rovna vážené sumě top-k výsledků
  - Alternativní přístupy
    - Získání query a dokument ebmeddingu => sjednocení a výpočet skóre
    - Fůze BERT modelu a jiného modelu pro výpočet relevance

- TransformerXL pro dlouhé dokumenty

Využití předtrénovaných jazykových modelů

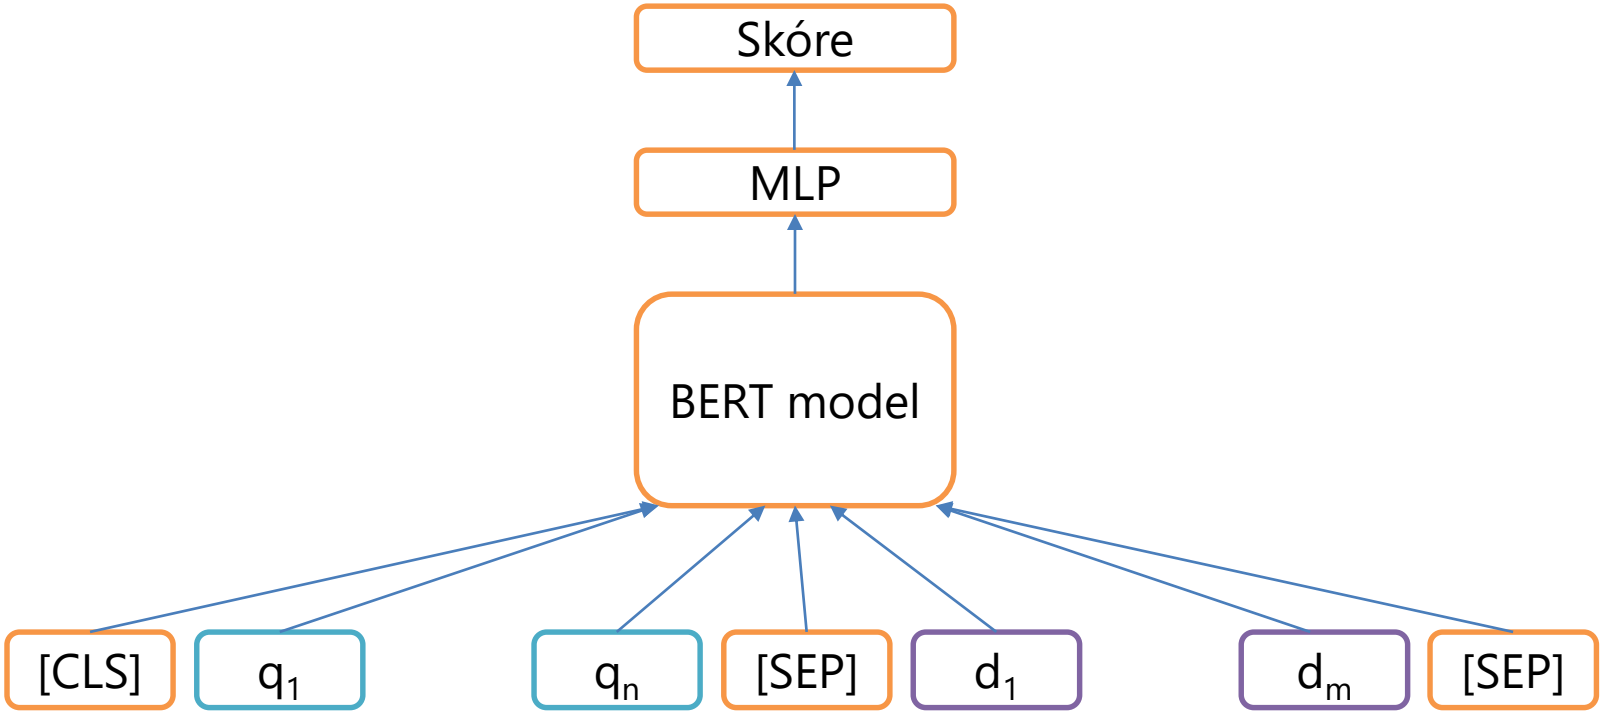

Vícejazyčné vyhledávání

- Rozšíření standardního vyhledávání
  - Detekce jazyka
    - LSTM neuronová síť
  - Strojový překlad
    - Transformer modely
  - Vícejazyčný embedding
    - Transformer modely (2021, Facebook AI)

- Překlad dotazu vs dokumentu

Užitečná literatura / kurzy

- TEOFILI, Tommaso. *Deep learning for search*. Shelter Island: Manning, [2019]. ISBN 978-161-7294-792.
- Neural Ranking Models For Document Retrieval (2021)
  - 2021 – aktuální shrnutí modelů neuronových sítí používaných pro hodnocení dokumentů